

GUÍA DE PRÁCTICA

Taller 3 · Análisis de Redes Complejas con Gephi

Script para la presentación + preguntas del profe
con respuestas listas para usar

Para las dos personas — incluyendo quien no sabe nada todavía

■ **Cómo usar esta guía:** léela completa antes de la presentación. Cada concepto tiene una analogía para entenderlo fácil. El script dice exactamente qué dice cada uno. Las preguntas del profe tienen respuesta lista.

PARTE 0 — ¿De qué se trata esto? (lee esto primero)

¿Qué es una red de colaboración científica?

Imagina que cada investigador del mundo es una persona en Instagram. Cada vez que dos investigadores publican un artículo juntos, se 'siguen mutuamente'. El dataset ca-GrQc es como el Instagram de los físicos que estudian relatividad general y cosmología cuántica entre 1993 y 2003.

■ **Analogía clave:** Nodo = persona. Arista = publicaron juntos. Red = el Instagram de los físicos.

¿Qué hicimos con Gephi?

Gephi es un programa que visualiza redes y calcula estadísticas sobre ellas. Nosotros importamos la red de los físicos y le preguntamos: ¿quiénes son los más importantes?, ¿hay grupos?, ¿quién conecta a quién?

Los números clave del dataset:

Qué	Número	Qué significa en simple
Nodos (autores)	5.242	5.242 físicos distintos en la red
Aristas (colaboraciones)	14.496	14.496 pares que publicaron juntos
Componentes conexos	355	355 grupos separados — como 355 islas en el océano
Componente principal	4.158 nodos (79,3%)	La isla más grande donde vive la mayoría
Grado promedio	5,53	En promedio, cada físico publicó con solo 5 o 6 colegas

■■ **Por qué usamos solo el componente principal (4.158 nodos):** si calculas métricas sobre las 355 islas separadas, los resultados no tienen sentido. Por ejemplo, un físico que publicó solo con su colega en una islita aparecería como 'el más cercano de todos' — ¡porque solo tiene 1 vecino! Así que trabajamos solo con la isla grande.

PARTE 1 — Las 4 Métricas (con analogías)

1.1 Eigenvector Centrality — ¿Quién es el más influyente?

■ **Analogía:** No es lo mismo tener 100 amigos cualquiera que tener 100 amigos famosos. El Eigenvector mide esto: si tus coautores son muy importantes, tú también subes. Es como el PageRank de Google para científicos.

Un físico con Eigenvector alto no necesariamente publicó con muchos, sino que los pocos o muchos con quienes publicó son también muy importantes.

Nuestros resultados — Top 3:

- Nodo 21012 → 0,1556 (puesto 1°)
- Nodo 2741 → 0,1536 (puesto 2°)
- Nodo 12365 → 0,1531 (puesto 3°)

Respuesta a la pregunta del profe: 'Ser influyente en esta red significa estar rodeado de coautores que también son importantes. No basta con publicar mucho — importa con quién publicas. El nodo 21012 tiene 81 colaboraciones con autores igualmente activos, lo que lo convierte en el núcleo de la red.'

1.2 Degree Centrality — ¿Quién más colabora?

■ **Analogía:** Simplemente: ¿cuántos números de teléfono tienes en tus contactos? No importa si son importantes o no. Solo cuántos son.

El grado promedio de esta red es 5,53. El nodo 21012 tiene 81. Eso es 15 veces más que el promedio — es un outlier enorme.

Nuestros resultados — Top 3:

- Nodo 21012 → 81 coautores (puesto 1°)
- Nodo 21281 → 79 coautores (puesto 2°)
- Nodo 22691 y 12365 → 77 coautores (puesto 3° (empate))

Diferencia entre influyente y colaborativo: el nodo 21281 tiene 79 coautores (2° en Degree) pero NO aparece en el top de Eigenvector. Eso significa que sus coautores son menos importantes. En cambio, nodos como 2741 tienen menos coautores pero sí aparecen en Eigenvector porque publican con gente muy conectada. **Ser prolífico ≠ ser influyente.**

1.3 Betweenness Centrality — ¿Quién conecta grupos distintos?

■ **Analogía:** Imagina una fiesta donde hay 5 grupos de amigos distintos que no se conocen entre sí. Pero tú conoces a alguien de cada grupo. Eres el puente. Sin ti, esos grupos no se conectan. Eso es el Betweenness: mide cuántos caminos entre otros pasan por ti.

Un valor de 0,059 (nodo 13801) significa que el 5,9% de TODOS los caminos más cortos entre pares de autores de la red pasan por ese nodo.

Nuestros resultados — Top 3:

- Nodo 13801 → 0,0589 (comunidad C0) (puesto 1°)
- Nodo 9572 → 0,0408 (comunidad C0) (puesto 2°)
- Nodo 14599 → 0,0405 (comunidad C0) (puesto 3°)

¿Qué pasa si los eliminamos? Si sacamos al nodo 13801, el 5,9% de las conexiones de la red se cortan. Las comunidades C1, C2 y C3 (que en total tienen el 24% de los nodos) quedarían parcialmente aisladas porque dependen de estos puentes para conectarse al resto. Es como cortar el único puente entre dos ciudades.

1.4 Closeness Centrality — ¿Quién difunde información más rápido?

■ **Analogía:** ¿Quién puede pasar el chisme más rápido en la escuela? El que está en el centro del patio y conoce a alguien de cada grupo. Closeness mide qué tan 'central' estás geográficamente en la red: cuántos pasos necesitas para llegar a todos.

El nodo 13801 tiene Closeness = 0,245. Eso significa que llega a cualquier autor en promedio en 4,08 pasos ($1/0,245$). El promedio de la red necesita 6,05 pasos.

Nuestros resultados — Top 3:

- Nodo 13801 → 0,2449 = aprox. 4,08 pasos (puesto 1°)
- Nodo 14485 → 0,2390 = aprox. 4,18 pasos (puesto 2°)
- Nodo 9572 → 0,2383 = aprox. 4,20 pasos (puesto 3°)

¿Por qué difunden más rápido? Están en el centro geográfico de la red. Un hallazgo científico que parta de ellos llega a más investigadores en menos intermediarios. También son los primeros en enterarse de avances de otros grupos. Ventaja clara en una red de conocimiento.

PARTE 2 — Cuadro Comparativo: ¿quién aparece en más rankings?

La tarea pide un cuadro comparativo para ver qué autores dominan en más métricas. De los 27 autores que aparecen en algún top 10, estos son los más versátiles:

Nodo	Degree	Eigenvector	Betweenness	Closeness	Total
21012	✓ #1	✓ #1	—	✓ #6	3 de 4
12365	✓ #3	✓ #3	—	✓ #9	3 de 4
17655	✓ #8	—	✓ #10	✓ #4	3 de 4
2741	✓ #9	✓ #2	—	—	2 de 4
13801	—	—	✓ #1	✓ #1	2 de 4
9572	—	—	✓ #2	✓ #3	2 de 4
14485	—	—	✓ #7	✓ #2	2 de 4
...otros 20 nodos	(1 métrica c/u)	—	—	—	1 de 4

Conclusión del cuadro: nadie domina las 4 métricas a la vez. El nodo 21012 es el más 'completo' (top en colaboraciones, influencia y cercanía). El nodo 13801 es el más estratégico (lidera Betweenness y Closeness, aunque no tenga tantos coautores). Hay perfiles distintos de importancia en la red.

PARTE 3 — Comunidades de Autores

¿Qué es el algoritmo de Modularidad?

■ **Analogía:** Es como detectar los grupos de WhatsApp dentro de una lista de contactos. El algoritmo mira quién chatea más con quién y los agrupa automáticamente. Aquí 'chatear' = co-publicar. El resultado $Q = 0,80$ significa que los grupos detectados son muy reales (entre 0 y 1, más cercano a 1 = mejor).

Resultados generales:

- **63 comunidades detectadas** sobre el componente principal.
- **Modularidad $Q = 0,80$** → estructura comunitaria muy marcada (muy bueno).
- La comunidad más grande (C0) tiene **901 nodos** = el 21,7% de todos.
- **10 comunidades grandes** (>100 nodos), 18 medianas, 35 pequeñas.

¿Está fragmentada o concentrada? Es un punto intermedio. Hay un grupo dominante (C0) pero también muchos grupos chicos y medianos. Cada comunidad probablemente representa una línea de investigación específica dentro de la relatividad general: agujeros negros, ondas gravitacionales, cosmología inflacionaria, gravedad cuántica de lazos, etc.

Comunidad más grande — C0 (901 nodos):

- **Nodos:** 901 | **Aristas:** 2.150 | **Densidad:** 0,0053 (baja — es grande y dispersa)
- **Clustering promedio:** 0,51 → si dos autores comparten un coautor, hay 51% de que también colaboren entre sí
- **Más influyente (Eigenvector):** Nodo 13929
- **Más colaborativo (Degree):** Nodo 13801 (38 coautores dentro de C0)
- **Mayor intermediación (Betweenness):** Nodo 14599
- **¿Es central?** Sí — el nodo 13801 tiene el mayor Betweenness y Closeness de TODA la red

Importante para responder: tres autores distintos lideran cada métrica en C0. No hay un solo 'jefe'. Hay liderazgos especializados: uno es el más influyente, otro el más colaborativo, otro el que une los subgrupos.

Comunidad más compacta — C17 (47 nodos):

- **Nodos:** 47 | **Aristas:** 739 | **Densidad:** 0,684 (muy alta)
- **Clustering:** 0,860 → si A y B comparten un coautor, hay 86% que A y B también publiquen juntos
- **En comparación:** C0 tiene densidad 0,005 — C17 es 137 veces más densa
- El 68,4% de TODAS las colaboraciones posibles entre sus 47 miembros existen
- **Liderazgo:** Nodo 6512 lidera, pero los nodos 16654 y 17807 tienen casi los mismos valores

¿Por qué es compacta? Porque casi todos colaboran con todos. Es como un equipo de investigación del mismo laboratorio o proyecto específico. **Liderazgo compartido** entre 3 autores → la comunidad es más resiliente. **Riesgo:** tan cerrada que puede ser una 'cámara de eco' — poca conexión con afuera.

PARTE 4 — Script de la Presentación (quién dice qué)

■ **Tiempo total: 10–15 minutos.** Persona A habla en las slides de métricas (slides 3–6 + slide 8). Persona B habla en la slide del dataset, cuadro comparativo, comunidades y conclusiones. Pueden intercambiar si prefieren. Lo importante es que AMBOS entiendan TODO por si el profe pregunta a cualquiera.

Slide 1 — Portada (15 seg)

■ Persona B:

"Buenas, somos ... y ... vamos a presentar el Taller 3 sobre análisis de redes complejas usando Gephi, con la red de colaboración científica ca-GrQc de Stanford."

Slide 2 — Dataset (1–2 min)

■ Persona B:

"La red que analizamos representa colaboraciones entre físicos que publicaron en arXiv entre 1993 y 2003. Cada nodo es un autor y cada arista significa que dos autores publicaron juntos al menos una vez. Tiene 5.242 autores y 14.496 colaboraciones. Importante: la red tiene 355 grupos separados, así que todos los cálculos los hicimos solo sobre el grupo principal de 4.158 nodos — si no, los resultados salen mal por los grupos aislados."

Slide 3 — Eigenvector Centrality (2 min)

■ Persona A:

"La primera métrica es el Eigenvector Centrality. Básicamente mide qué tan importantes son tus coautores — no solo cuántos tienes. El nodo con ID 21012 tiene el valor más alto con 0,156. Esto significa que no solo tiene 81 colaboraciones, sino que esos coautores también son muy activos e influyentes. La pregunta del profe era qué significa ser influyente acá: ser influyente es estar en el núcleo de la red, rodeado de gente igual de activa. No es lo mismo publicar con cualquiera que publicar con los más conectados."

Slide 4 — Degree Centrality (1.5 min)

■ Persona A:

"El Degree simplemente cuenta con cuántos autores distintos publicaste. El nodo 21012 de nuevo lidera con 81 colaboraciones — 15 veces más que el promedio. La diferencia con Eigenvector es clara: el nodo 21281 tiene 79 coautores pero no aparece entre los más influyentes, porque sus coautores son menos importantes. Sí se observa una concentración fuerte — pocos autores acumulan casi todas las colaboraciones, lo que es típico de una red libre de escala."

Slide 5 — Betweenness Centrality (2 min)

■ Persona A:

"El Betweenness mide cuántos caminos entre otros pares de autores pasan por ti. El nodo 13801 tiene el valor más alto: el 5,9% de todos los caminos de la red pasan por él. Si lo eliminamos, esos caminos se cortan. Sobre la pregunta de comunidades que dependen de estos nodos: los nodos 13801, 9572 y 14599 están en la comunidad C0 pero actúan como puentes hacia C1, C2 y C3. Si los sacamos, esas comunidades que representan el 24% de la red quedarían parcialmente aisladas."

Slide 6 — Closeness Centrality (1.5 min)

■ Persona A:

"El Closeness mide qué tan cerca estás de todos en la red. El nodo 13801 lidera acá también con 0,245, lo que significa que puede llegar a cualquier autor en solo 4 pasos, mientras el promedio necesita 6. Por eso pueden difundir conocimiento más rápido: su trabajo llega a más personas en menos intermediarios. Son como el 'centro geográfico' de la red."

Slide 7 — Cuadro Comparativo (1.5 min)

■ Persona B:

"Acá vemos quién aparece en más rankings. Hay 27 autores que aparecen en algún top 10. Solo 3 aparecen en 3 métricas: el 21012, el 12365 y el 17655. El 21012 es el más completo — top en colaboraciones, influencia y cercanía. Pero hay un punto interesante: el nodo 13801 aparece solo en 2 métricas, pero lidera Betweenness y Closeness, que son las más importantes para la cohesión de la red. Es más estratégico que el 21012 a pesar de tener menos coautores. Esto confirma que influencia es multidimensional — no hay un solo tipo de importancia."

Slide 8 — Comunidades: Modularidad (2 min)

■ Persona B:

"Usamos el algoritmo de Modularidad de Gephi para detectar comunidades. Encontramos 63 comunidades con un valor Q de 0,80, que es muy alto — significa que los grupos son reales y bien definidos. La red no está ni completamente fragmentada ni centralizada: hay una comunidad grande, C0 con 901 nodos, y muchas pequeñas. Cada comunidad probablemente representa una línea de investigación distinta dentro de la física teórica."

Slide 9 — Comunidad más grande C0 (1.5 min)

■ Persona B:

"La comunidad C0 tiene 901 nodos, 2.150 aristas y una densidad baja de 0,005. Pero su clustering de 0,51 es sorprendentemente alto para su tamaño. Algo importante: los tres autores que lideran cada métrica dentro de C0 son distintos. No hay un solo jefe sino tres roles especializados. ¿Es central? Sí — el nodo 13801, que vive en C0, tiene el mayor Betweenness y Closeness de toda la red."

Slide 10 — Comunidad más compacta C17 (1.5 min)

■ Persona B:

"Entre las comunidades con más de 20 autores, C17 es la más compacta con densidad 0,684 y clustering 0,860. Eso significa que el 68% de todas las colaboraciones posibles entre sus 47 miembros existen de verdad. Es casi como si todos publicaran con todos. Probablemente es un equipo de investigación de una misma institución. El liderazgo está repartido entre 3 autores con valores casi idénticos, lo que hace a la comunidad resiliente. El riesgo es que sea muy cerrada hacia afuera."

Slide 11 — Conclusiones (1 min)

■ Persona B:

"Para cerrar, los cinco hallazgos principales: primero, la red es libre de escala — pocos concentran muchas colaboraciones. Segundo, ser colaborativo, influyente, puente y cercano son cosas distintas. Tercero, el nodo 13801 es el más crítico para la cohesión de la red. Cuarto, hay 63 comunidades bien definidas que probablemente representan líneas de investigación específicas. Y quinto, C0 es el núcleo disperso y C17 es el equipo compacto — dos extremos dentro de la misma red."

PARTE 5 — Preguntas que puede hacer el Profe

■■■ Estas son las preguntas más probables. **Cualquiera de los dos** debe poder responder cualquiera. Léanlas en voz alta juntos antes de la presentación.

■ Pregunta 1: ¿Por qué calcularon las métricas solo sobre el componente principal y no sobre toda la red?

Porque las métricas que usan caminos más cortos (Betweenness y Closeness) no tienen sentido entre nodos que no están conectados. Si las calculas sobre el grafo completo, un nodo aislado con un solo vecino obtiene Closeness = 1,0 — lo que es un error, no un resultado real. Por eso la práctica estándar es trabajar solo con el componente principal.

■ Pregunta 2: ¿Qué es una red libre de escala?

Es una red donde pocos nodos tienen muchas conexiones y la mayoría tiene muy pocas. La distribución de grados sigue una ley de potencia: hay un nodo con 81 coautores mientras el promedio es 5,53. Es como en Instagram: unos pocos influencers tienen millones de seguidores y el 99% tiene decenas. Este fenómeno ocurre en redes donde 'el rico se hace más rico' — los autores ya famosos atraen más colaboradores.

■ Pregunta 3: ¿Qué significa una modularidad $Q = 0,80$?

La modularidad va de 0 a 1. Un valor cercano a 1 significa que las comunidades detectadas son muy reales: hay muchas conexiones dentro de cada grupo y pocas conexiones entre grupos. Con $Q = 0,80$ podemos confiar en que las 63 comunidades detectadas reflejan agrupaciones reales de investigadores, no son aleatorias.

■ Pregunta 4: ¿Por qué el nodo 21012 no aparece entre los de mayor Betweenness?

Porque sus colaboraciones son densas dentro de su propia comunidad (C0), no entre comunidades distintas. El Betweenness mide puentes entre grupos, y el 21012 es muy activo dentro de un grupo pero no conecta grupos diferentes. El nodo 13801, en cambio, tiene pocas colaboraciones pero las que tiene conectan comunidades que de otro modo no se hablarían.

■ Pregunta 5: ¿Qué diferencia hay entre Closeness y Betweenness?

Ambos miden 'posición en la red' pero de formas distintas. Betweenness mide cuántos caminos entre otros pasan por ti — eres un puente. Closeness mide qué tan corta es tu distancia promedio al resto — estás en el centro. Pueden coincidir (el 13801 lidera ambas) o no (el 21012 tiene alto Closeness pero bajo Betweenness). Son dimensiones distintas de la centralidad.

■ Pregunta 6: Si eliminas los top 3 de Betweenness, ¿qué le pasa a la red?

Probablemente el componente principal se fragmenta en varios subcomponentes. Los nodos 13801, 9572 y 14599 están en C0 y actúan como puentes hacia C1, C2 y C3. Si los eliminamos, esas comunidades que representan el 24% de los nodos quedarían parcialmente aisladas. La distancia promedio entre los autores restantes aumentaría significativamente.

■ Pregunta 7: ¿Qué representa cada comunidad en términos reales?

Probablemente cada comunidad es una línea de investigación específica dentro de la relatividad general y cosmología cuántica: grupos de agujeros negros, ondas gravitacionales, cosmología inflacionaria, gravedad cuántica de lazos, etc. También pueden representar grupos de una misma institución o que comparten metodologías similares. No podemos saberlo con certeza porque los IDs son anónimos.

■ Pregunta 8: ¿Por qué C17 es más compacta que C0 si C0 es mucho más grande?

Porque la densidad no depende del tamaño — depende de la proporción de conexiones existentes sobre las posibles. C0 tiene 901 nodos: las posibles conexiones son $901 \times 900 / 2 = 405.450$, pero solo tiene 2.150 → densidad 0,005. C17 tiene 47 nodos: las posibles son $47 \times 46 / 2 = 1.081$, y tiene 739 → densidad 0,684. Grupos pequeños y cohesionados siempre tienen más densidad que grupos grandes y dispersos.

■ Pregunta 9: ¿Qué es el coeficiente de clustering?

Mide qué probabilidad hay de que dos vecinos de un nodo también sean vecinos entre sí. Clustering = 0,86 en C17 significa: si A y B son coautores del mismo autor, hay 86% de probabilidad de que A y B también hayan publicado juntos. Es una medida de qué tanto se forman triángulos de colaboración en la red.

■ Pregunta 10: ¿Cuál de los dos autores eliminó más 'daño' a la red: el 21012 o el 13801?

El 13801 causa más daño estructural. El 21012 tiene más colaboraciones, pero sus conexiones son densas dentro de C0. Si lo sacas, C0 pierde su autor más colaborativo pero la red sigue conectada. El 13801 en cambio lidera Betweenness y Closeness: es el puente entre C0 y otras comunidades. Sin él, partes de la red se desconectan. Es el nodo más crítico para la cohesión global.

■ Pregunta 11: ¿Gephi les da el valor de Closeness correcto cuando hay componentes desconectados?

No directamente — ese es un punto metodológico importante que manejamos. Gephi calcula Closeness por componente, lo que hace que nodos en componentes pequeños obtengan valores artificialmente altos (un nodo con un solo vecino tiene distancia 1 a su único vecino → Closeness = 1,0). Por eso filtramos el grafo al componente principal antes de calcular.

PARTE 6 — Glosario Rápido (para memorizar los términos)

Término	En simple	Analogía
Nodo	Un autor (persona)	Una persona en Instagram
Arista	Una co-publicación	Seguirse mutuamente
Grado (Degree)	N° de coautores	N° de contactos en el teléfono
Eigenvector	Influencia ponderada por vecinos	Tener amigos famosos
Betweenness	% de caminos que pasan por ti	El único que conoce a todos los grupos
Closeness	Inverso de distancia promedio	El que pasa el chisme más rápido
Modularidad Q	Qué tan bien definidas están las comunidades	Qué tan claros son los grupos de WhatsApp
Densidad	% de conexiones existentes vs. posibles	Qué tan amigos son todos entre sí
Clustering	Prob. que dos vecinos sean vecinos entre sí	Si tus dos mejores amigos se conocen
Componente principal	El grupo más grande conectado	La isla más grande
Red libre de escala	Pocos nodos con muchas conexiones	Influencers vs. usuarios normales

División de roles entre los dos:

Persona A (slides 3–6)	Persona B (slides 2, 7–11)
• Explica Eigenvector Centrality • Explica Degree Centrality • Explica Betweenness Centrality • Explica Closeness Centrality • Maneja las tablas y gráficos de métricas • Sabe responder preguntas 4, 5, 6, 11	• Presenta el dataset y contexto • Explica el cuadro comparativo • Explica comunidades y Modularidad • Analiza C0 y C17 • Entrega las conclusiones • Sabe responder preguntas 1, 2, 3, 7, 8, 9, 10

■ **Tip final:** el profe puede preguntarle a cualquiera sobre cualquier tema. Léanse los scripts del otro también. En especial la diferencia entre las 4 métricas y por qué usamos solo el componente principal — eso seguro lo pregunta.